

Pontificia Universidad Javeriana Cali
Facultad de Ingeniería y Ciencias
Ingeniería de Sistemas y Computación
Trabajo de Grado

Sistema de soporte a la toma de decisiones para un restaurante pyme basado en modelos de predicción de demanda con Machine Learning e Ingeniería de Menú

Rui Yu Lei Wu
Juan David Bernal Maldonado

Director
(Magíster en Ingeniería) Mario Julián Mora Cardona

Mes de 2026



Carta de Aprobación

Santiago de Cali, [fecha de entrega]

Señores

Pontificia Universidad Javeriana Cali

Dr. Gerardo Mauricio Sarria

Director de Carrera, Ingeniería de Sistemas y Computación

Cali

Cordial saludo,

Por medio de la presente me permito informarle que los estudiantes de Ingeniería de Sistemas y Computación, **Rui Yu Lei Wu** (cód: 8978227) y **Juan David Bernal Maldonado** (cód: 8977771), trabajaron bajo mi dirección en el proyecto de grado titulado **Sistema de soporte a la toma de decisiones para un restaurante pyme basado en modelos de predicción de demanda con Machine Learning e Ingeniería de Menú**, el cual se encuentra finalizado y listo para sustentación.

Atentamente,

(**Magíster en Ingeniería**) Mario Julián Mora Cardona

Carta de Compromiso

Santiago de Cali, [fecha de entrega]

Señores

Pontificia Universidad Javeriana Cali

Dr. Gerardo Mauricio Sarria

Ingeniería de Sistemas y Computación

Cali

Cordial saludo,

Nos permitimos presentar a su consideración el trabajo de grado titulado **“Sistema de soporte a la toma de decisiones para un restaurante pyme basado en modelos de predicción de demanda con Machine Learning e Ingeniería de Menú”**, con el fin de cumplir con los requisitos exigidos por la Universidad para optar al título de Ingeniero(a) de Sistemas y Computación.

Mediante la presente, declaramos que este trabajo ha sido desarrollado por nuestra autoría, bajo la dirección del profesor Mario Julián Mora Cardona, y que cumple con las normas académicas establecidas por la Facultad de Ingeniería y Ciencias. Asimismo, damos fe que entendemos y conocemos la directriz 35/2024 para la presentación de trabajos de grado en los programas académicos de pregrado, aprobada el 17 de junio de 2024 por la Vicerrectoría Académica.

De igual manera, nos comprometemos a asumir la responsabilidad sobre el contenido, los resultados y las conclusiones presentadas en este documento.

Atentamente,

*Rui Yu Lei Wu**Juan David Bernal Maldonado*

Rui Yu Lei Wu

Juan David Bernal Maldonado

Código: 8978227

Código: 8977771

Abstract

Small and medium-sized restaurants manage their operational planning by intuition, without tools that turn their sales data into useful information for deciding which dishes to promote and which to remove from the menu. This work builds a prototype decision support system that integrates Machine Learning-based demand prediction models with a menu engineering module, presenting the results in a web dashboard accessible to administrators without technical training. The system is developed and evaluated on the public *Small Restaurant Multi-Channel Data 2023–2025* dataset, and its performance is measured using MAE, RMSE and SMAPE. Integrating demand prediction and menu engineering analysis within a single system addresses a gap documented in the academic literature.

Keywords: demand forecasting, menu engineering, machine learning, decision support system, small and medium-sized restaurants, profitability, time series.

Abstract

Los restaurantes pequeños y medianos gestionan su planificación operativa por intuición, sin herramientas que conviertan sus datos de ventas en información útil para decidir qué promover y qué retirar del menú. Este trabajo construye un prototipo de sistema de soporte a la toma de decisiones que integra modelos de predicción de demanda basados en Machine Learning con un módulo de ingeniería de menú, y presenta los resultados en un dashboard web accesible para administradores sin formación técnica. El sistema se desarrolla y evalúa sobre el conjunto de datos público *Small Restaurant Multi-Channel Data 2023–2025*, y su desempeño se mide mediante MAE, RMSE y SMAPE. La integración de predicción de demanda y análisis de ingeniería de menú en un mismo sistema cubre una brecha documentada en la literatura académica.

Palabras clave: predicción de demanda, ingeniería de menú, machine learning, sistema de soporte a la toma de decisiones, restaurantes PyMEs, rentabilidad, series de tiempo.

Índice general

Carta de Aprobación	i
Carta de Compromiso	ii
1 Introducción	1
2 Planteamiento del Problema	2
2.1 Descripción del problema	2
2.1.1 Formulación del problema	3
2.1.2 Sistematización del problema	3
2.2 Objetivos del Proyecto	4
2.2.1 Objetivo General	4
2.2.2 Objetivos Específicos	4
2.3 Justificación	5
2.4 Alcance y Limitaciones	6
2.4.1 Alcance	6
2.4.2 Limitaciones	6
2.4.3 Exclusiones	7
2.4.4 Entregables	7
2.5 Metodología	7
2.5.1 Tipo de Estudio	7
2.5.2 Fases del proyecto	8
3 Marco Teórico y Trabajos Relacionados	10
3.1 Marco de Referencia	10
3.2 Trabajos Relacionados y Diferenciadores del Proyecto	12
3.2.1 Trabajos Relacionados	12
3.2.2 Diferenciadores del Proyecto	13
4 Caracterización del Conjunto de Datos	14
4.1 Descripción general del conjunto de datos	14
4.2 Análisis exploratorio	15
4.2.1 Estacionalidad	15

4.2.2	Tendencia	16
4.2.3	Distribución por categoría y por plato	17
4.3	Estructura de costos y margen	18
4.4	Variables de demanda y rentabilidad	18
5	Diseño del Sistema	20
5.1	Especificación de requisitos	20
5.1.1	Requisitos funcionales	20
5.1.2	Requisitos no funcionales	20
5.1.3	Restricciones del sistema	20
5.2	Arquitectura del sistema	20
5.2.1	Visión general de la arquitectura	20
5.2.2	Módulo de ingesta de datos	21
5.2.3	Módulo de predicción de demanda	21
5.2.4	Módulo de ingeniería de menú	21
5.2.5	Interfaz de visualización	21
5.3	Flujos de información entre módulos	21
5.4	Decisiones pendientes de validación	21
6	Desarrollo del Prototipo	26
6.1	Preprocesamiento de los datos	27
6.2	Módulo de predicción de demanda	27
6.2.1	Modelo XGBoost	27
6.2.2	Modelo LSTM	27
6.2.3	Selección del modelo	27
6.3	Módulo de ingeniería de menú	27
6.3.1	Cálculo del margen de contribución ponderado	27
6.3.2	Clasificación dinámica del menú	27
6.4	Dashboard web	27
6.4.1	Tecnologías empleadas	27
6.4.2	Funcionalidades implementadas	27
6.5	Integración del sistema	27

7	Validación del Sistema y Resultados	28
7.1	Métricas de evaluación	29
7.2	Resultados de los modelos de predicción	29
7.2.1	Resultados de XGBoost	29
7.2.2	Resultados de LSTM	29
7.2.3	Comparación de desempeño	29
7.3	Validación funcional del prototipo	29
7.4	Análisis de resultados	29
8	Conclusiones	30
9	Trabajo Futuro	31
	Anexo: Declaración sobre el uso de Inteligencia Artificial	32
	Bibliografía	33

Índice de cuadros

4.1	Diccionario de datos del archivo transaccional	15
4.2	Demanda y ventas por año	16
4.3	Platos, unidades y ventas por categoría	17
4.4	Variables identificadas para los módulos del sistema	19
5.1	Requisitos funcionales (formato tipo IEEE)	23
5.2	Requisitos no funcionales (formato tipo IEEE)	24
5.3	Restricciones del sistema	24
5.4	Flujos de información entre módulos	25

Índice de figuras

4.1	Unidades vendidas por día de la semana, 2023–2025. No hay operación los domingos.	16
4.2	Demanda mensual total, enero de 2023 a diciembre de 2025.	17
5.1	Flujo de información entre los módulos del sistema.	22

CAPÍTULO 1

Introducción

Los restaurantes pequeños y medianos generan datos de ventas todos los días, pero toman sus decisiones operativas más críticas sin analizarlos. Qué platos promover y cuáles retirar del menú son preguntas que la mayoría de administradores responden con experiencia e intuición, no con información cuantitativa. Esa brecha entre los datos disponibles y las decisiones que se toman tiene un costo financiero directo: sobreproducción que deteriora insumos, desabastecimiento que pierde ventas, y platos en el menú que reducen la rentabilidad del negocio sin que el administrador lo sepa.

La literatura científica ha resuelto partes del problema. Los modelos de Machine Learning predicen la demanda en restaurantes con precisión superior a los métodos manuales, y la ingeniería de menú clasifica los platos según su rentabilidad y popularidad para orientar decisiones de precio y posicionamiento. Sin embargo, ambas líneas han avanzado por separado, y los sistemas documentados fueron diseñados para cadenas con infraestructura tecnológica que un restaurante independiente no tiene.

Este trabajo propone un sistema de soporte a la toma de decisiones que integra un módulo de predicción de demanda basado en Machine Learning con un módulo de ingeniería de menú, y presenta los resultados en un dashboard web accesible para el administrador. El sistema se desarrolla sobre datos reales de un restaurante de pequeño formato y se evalúa con métricas estándar de error predictivo.

Planteamiento del Problema

2.1 Descripción del problema

Los restaurantes PyME gestionan su planificación operativa mediante registros manuales de ventas y la experiencia del administrador, sin incorporar variables externas como condiciones climáticas, días festivos o eventos locales que inciden directamente sobre la demanda [1, 2]. Esta práctica produce dos consecuencias operativas concretas: la sobreproducción, que deteriora insumos y eleva costos, y el desabastecimiento, que genera pérdida de ventas y deterioro de la experiencia del cliente [3]. En paralelo, sin un análisis sistemático del margen de contribución por plato, las decisiones de precio, posicionamiento y ajuste del menú se toman sin respaldo cuantitativo, lo que impide identificar qué ítems sostienen la rentabilidad del negocio y cuáles la erosionan [4, 5].

Este problema se agudiza en Colombia, donde Muñoz-Pinzón et al. [6] documentaron una baja adopción generalizada de herramientas tecnológicas digitales en PyMEs, con barreras comunes asociadas a la falta de infraestructura y los altos costos de inversión. El sector gastronómico, que aportó el 3,9% del PIB nacional en 2022 y generó cerca de 1,5 millones de empleos [7], atravesó en 2023 uno de sus periodos más críticos desde la pandemia: el DANE reportó que el índice de precios al consumidor en el rubro de restaurantes y hoteles registró una variación anual del 13,22% al cierre de 2023, mientras que la inflación de alimentos y bebidas no alcohólicas superó el 26% en enero de ese mismo año [8]. Ante este escenario, Acodres estimó una caída en ventas del 29% durante 2023, con el cierre de más de 1.600 restaurantes en el país [9].

La literatura científica ha abordado por separado los dos componentes del problema. Por un lado, los modelos de Machine Learning han demostrado capacidad predictiva superior a los métodos tradicionales de estimación de demanda en restaurantes [1, 2, 10, 11]. Sin embargo, estos modelos fueron desarrollados en condiciones que los restaurantes PyME no pueden replicar: Schmidt et al. [1] modelan ventas agregadas del establecimiento sin desagregarlas por plato individual, lo que impide derivar decisiones de rentabilidad por ítem; Kim [2] requiere historiales de cientos de ítems con años de datos limpios y variables meteorológicas

estructuradas; y Chae et al. [11] trabajan exclusivamente con cadenas multinacionales que disponen de infraestructura de datos consolidada. El estudio más orientado a PyMEs, Groene y Zakharov [10], demuestra que XGBoost supera la estimación manual en entornos con recursos limitados, pero tampoco integra análisis de rentabilidad ni propone una interfaz operativa para el administrador.

Por otro lado, la ingeniería de menú clasifica cada plato según su margen de contribución y su popularidad relativa [4], pero esta clasificación pierde utilidad operativa cuando se realiza sobre datos históricos sin proyección: un plato con margen alto pero demanda decreciente requiere una intervención distinta a uno con demanda estable [5]. Las metodologías de ingeniería de menú han avanzado de forma independiente, sin conexión con modelos predictivos que permitan anticipar el comportamiento futuro de cada ítem.

Bujalance-López et al. [12], tras analizar 108 artículos publicados entre 1997 y 2023, confirmaron que la integración de predicción de demanda y análisis de rentabilidad en un solo sistema es la frontera de investigación más activa del campo, y que la mayoría de los sistemas documentados exige infraestructura tecnológica avanzada que excluye a los establecimientos de menor tamaño. No existe, en la literatura revisada, un sistema de soporte a la toma de decisiones que articule predicción de demanda, análisis de rentabilidad por plato y visualización operativa en un entorno accesible para restaurantes PyME.

2.1.1 Formulación del problema

¿En qué medida un sistema de soporte a la toma de decisiones que integre modelos de predicción de demanda basados en Machine Learning y análisis de ingeniería de menú mejora la calidad de la planificación operativa en restaurantes PyME, en comparación con los métodos de estimación actuales?

2.1.2 Sistematización del problema

Con el fin de descomponer la pregunta central en elementos abordables que orienten el diseño, desarrollo y validación del sistema, se plantean los siguientes interrogantes:

- ¿Qué factores y/o variables tienen mayor capacidad predictiva sobre la demanda diaria y semanal por ítem de menú?

- ¿Qué modelo de Machine Learning ofrece el mejor balance entre precisión predictiva y costo computacional para el contexto de un restaurante PyME?
- ¿Cómo debe integrarse la predicción de demanda con el análisis de ingeniería de menú para generar una clasificación dinámica del menú que oriente decisiones de precio y posicionamiento?
- ¿Cómo se integra el módulo predictivo, de ingeniería de menú y la visualización de forma que sea operable por un administrador sin formación técnica en ciencia de datos?
- ¿En qué medida las estimaciones de demanda generadas por el sistema alcanzan un desempeño predictivo adecuado para apoyar la toma de decisiones en el restaurante PyME?

2.2 Objetivos del Proyecto

2.2.1 Objetivo General

Construir un sistema de soporte a la toma de decisiones para un restaurante PyME, integrando predicción de demanda por plato basada en Machine Learning y análisis de ingeniería de menú, evaluado con métricas de desempeño predictivo sobre un conjunto de datos históricos de operación real.

2.2.2 Objetivos Específicos

1. Identificar los requerimientos funcionales del sistema DSS y las variables de demanda y rentabilidad del restaurante, mediante revisión documental y análisis exploratorio del conjunto de datos.
2. Describir los flujos de información del sistema entre el módulo de ingesta de datos, los modelos predictivos, el módulo de rentabilidad y la interfaz de visualización, estableciendo la integración necesaria para el funcionamiento del sistema de soporte a la toma de decisiones.
3. Desarrollar modelos de predicción de demanda bajo datos reales, utilizando técnicas de Machine Learning generando estimaciones confiables para la planificación operativa.

4. Probar el desempeño de los modelos de aprendizaje automático que integran el prototipo DSS mediante métricas de error, como MAE, RMSE y SMAPE, para determinar su capacidad predictiva como apoyo a la toma de decisiones.

2.3 Justificación

Los restaurantes PyME operan bajo condiciones financieras sensibles a la eficiencia operativa. Dado que los costos de alimentos representan entre el 28% y el 35% de las ventas según la National Restaurant Association [13], cualquier ineficiencia recurrente en la compra de insumos o en la gestión del menú tiene consecuencias directas sobre la rentabilidad del negocio. Este contexto convierte la planificación operativa basada en datos en una necesidad económica, no en una aspiración tecnológica.

El impacto potencial de resolver este problema es cuantificable. El World Resources Institute analizó 114 restaurantes en 12 países y encontró que por cada dólar invertido en programas de reducción de desperdicio alimentario, los establecimientos ahorraron en promedio siete dólares en costos operativos a lo largo de tres años, con una reducción del 26% en desperdicio durante el primer año de implementación [14].

El uso de modelos de predicción de demanda basados en Machine Learning ha demostrado un impacto significativo en la reducción del desperdicio alimentario. En particular, se ha evidenciado que su aplicación puede reducir entre un 14% y un 52% la cantidad de alimentos desperdiciados, además de disminuir la demanda insatisfecha entre un 3% y un 16% en comparación con métodos tradicionales [3]. En este contexto, una estimación de demanda más precisa representa una de las palancas de mayor impacto operativo y financiero disponibles para un administrador, sin necesidad de grandes inversiones de capital.

El beneficio no se limita a la reducción de desperdicio. Roy et al. [15] argumentan en la Harvard Business Review que los restaurantes que adoptan decisiones basadas en datos logran mejoras en eficiencia operativa, optimización de inventario y gestión de ingresos que los establecimientos que operan por intuición no alcanzan. Sin embargo, este tipo de herramientas ha estado históricamente disponible solo para cadenas con infraestructura tecnológica avanzada. Los restaurantes independientes carecen de acceso práctico a estas capacidades analíticas.

Este proyecto es relevante para dos grupos concretos. Para el administrador del restaurante, el sistema elimina la dependencia de la intuición en decisiones críticas y le entrega proyecciones

de demanda y clasificaciones de rentabilidad en lenguaje operativo, sin requerir formación en ciencia de datos. Para el sector gastronómico colombiano, que aportó el 3,9% del PIB en 2022 y genera cerca de 1,5 millones de empleos [7], la disponibilidad de herramientas accesibles de planificación puede contribuir a reducir la tasa de cierre de establecimientos y fortalecer la sostenibilidad financiera del sector.

2.4 Alcance y Limitaciones

2.4.1 Alcance

El presente proyecto construye un prototipo funcional de un sistema de soporte a la toma de decisiones para la planificación operativa de restaurantes PyME, que integra modelos de predicción de demanda basados en Machine Learning con un módulo de análisis de rentabilidad por ítem de menú fundamentado en ingeniería de menú. El sistema procesa registros transaccionales de ventas, genera proyecciones de demanda por plato para horizontes diarios y semanales, clasifica dinámicamente los ítems del menú según su margen de contribución y popularidad proyectada, y presenta los resultados a través de un dashboard web operativo accesible para administradores sin formación técnica en ciencia de datos y orientado por la ingeniería de menú.

El desarrollo y la validación se realizan sobre el conjunto de datos *Small Restaurant Multi-Channel Data 2023–2025* [16], disponible en Kaggle, que contiene 4.385 registros transaccionales de un restaurante independiente del Reino Unido con los campos: fecha, día de la semana, nombre del plato, categoría, cantidad vendida, precio por ítem (*Price Per Item*), costo estimado de producción (*Est. Cost*) y margen estimado (*Est. Profit*). El dataset cubre enero de 2023 a diciembre de 2025 con 62 platos distintos y los tres años completos. El sistema se entrena y valida sobre los datos de este único restaurante; sus parámetros reflejan los patrones de ese establecimiento específico.

2.4.2 Limitaciones

La predicción de demanda se aborda exclusivamente desde el comportamiento histórico de las ventas por plato, sin pretender modelar la totalidad de los factores externos que inciden sobre la demanda real de un restaurante. El sistema no tiene acceso a fichas técnicas de ingredientes ni a costos reales auditados del restaurante. Asimismo, la obtención

de datos transaccionales reales de un restaurante independiente implica restricciones de confidencialidad y disponibilidad que exceden el alcance de un proyecto de grado, razón por la cual se recurre a un conjunto de datos público como base de desarrollo y validación.

2.4.3 Exclusiones

El proyecto no contempla la integración con sistemas de punto de venta, el despliegue en entorno de producción, la gestión de inventarios, el desglose de costos por ingrediente o insumo, la incorporación de variables externas como condiciones climáticas o días festivos, ni la extensión del sistema a múltiples establecimientos. La generalización del sistema a contextos distintos del conjunto de datos utilizado queda como trabajo futuro.

2.4.4 Entregables

- Un documento de análisis de requerimientos y exploración de datos, que recoge los requisitos funcionales y no funcionales del sistema DSS, la identificación de las variables de demanda y rentabilidad relevantes para el contexto operativo del restaurante, y los resultados del análisis exploratorio sobre el conjunto de datos seleccionado.
- La descripción de los flujos de información entre el módulo de ingesta de datos, los modelos predictivos, el módulo de rentabilidad y la interfaz de visualización.
- El conjunto de modelos de predicción de demanda entrenados, acompañado del reporte de desempeño de los modelos desarrollados con sus respectivas métricas obtenidas para cada uno, y la selección justificada del modelo que se integra en el prototipo del sistema.
- El prototipo funcional del sistema DSS, que comprende el módulo de predicción de demanda, el módulo de ingeniería de menú y el dashboard web operativo.

2.5 Metodología

2.5.1 Tipo de Estudio

El proyecto corresponde a una investigación aplicada de carácter cuantitativo. Su propósito es construir un prototipo funcional que integre modelos de predicción de demanda basados

en machine learning con un módulo de ingeniería de menú, orientado a la toma de decisiones administrativas en restaurantes PyME. El estudio no contempla implementación en campo; el prototipo se desarrolla, entrena y evalúa en un entorno controlado a partir de datos históricos reales de un restaurante de tamaño pequeño o mediano, lo que permite probar su funcionamiento sin depender de una adopción operativa por parte del establecimiento.

El enfoque cuantitativo se justifica por la naturaleza de los datos involucrados: registros transaccionales de ventas, precios de venta y por la necesidad de probar el desempeño de los modelos mediante métricas objetivas de error pronóstico.

2.5.2 Fases del proyecto

Las actividades del proyecto se organizan en cinco fases secuenciales, cada una orientada a la construcción progresiva del sistema propuesto.

2.5.2.1 Recolección y preparación de datos

Se identificarán los requerimientos funcionales del sistema DSS. También, se trabajará con el conjunto de datos *UK Small Restaurant Multi-Channel Data* [16], el cual contiene registros históricos de las ventas de un restaurante independiente durante el periodo comprendido entre 2023 y 2025. El conjunto de datos incluye información de las transacciones realizadas, como la fecha de la venta, los productos vendidos, la cantidad, el precio por ítem, el valor total de la transacción, el canal de venta y variables financieras asociadas.

2.5.2.2 Análisis exploratorio de datos

Se realizará un análisis descriptivo de las series de tiempo de ventas por plato para identificar tendencias y patrones de estacionalidad semanal y mensual. Este análisis orientará la selección de las características de entrada para los modelos de predicción y permitirá identificar los platos con mayor variabilidad histórica, que representan los casos de mayor interés para el módulo de toma de decisiones. Sus resultados se documentan en el capítulo 4.

2.5.2.3 Desarrollo y evaluación del módulo de predicción de demanda

Se implementarán y compararán al menos dos modelos de machine learning para la predicción de ventas por plato: XGBoost, como modelo de referencia demostrado en entornos PyME

[10], y una red neuronal recurrente del tipo LSTM, que captura dependencias temporales de largo plazo [1]. Cada modelo será entrenado con un subconjunto de datos históricos y evaluado sobre un periodo de prueba reservado, usando como métricas el error absoluto medio (MAE), el error cuadrático medio (RMSE) y el error porcentual absoluto medio simétrico (SMAPE). El modelo con mejor desempeño en el conjunto de prueba será seleccionado para integrarse al sistema final.

2.5.2.4 Desarrollo del módulo de ingeniería de menú

Se implementará la metodología de Kasavana y Smith [17] para clasificar cada plato del menú en las cuatro categorías de la matriz: *estrella* (margen alto, popularidad alta), *caballo de arado* (margen bajo, popularidad alta), *puzzle* (margen alto, popularidad baja) y *perro* (margen bajo, popularidad baja). La clasificación se calculará tanto sobre datos históricos como sobre las proyecciones generadas por el módulo de predicción, lo que permitirá anticipar cambios en la categoría de cada plato y derivar recomendaciones de precio, promoción o ajuste del menú con base en el comportamiento futuro estimado.

2.5.2.5 Desarrollo del dashboard web e integración del sistema

Se diseñará e implementará una interfaz de visualización destinada al administrador del restaurante, que integrará los resultados del módulo de predicción y del módulo de ingeniería de menú en una presentación accesible para usuarios sin formación técnica. La interfaz incluirá gráficas de proyección de demanda por plato, la matriz de clasificación del menú con indicadores de rentabilidad, y alertas automáticas ante cambios significativos en la categoría proyectada de un plato.

Marco Teórico y Trabajos Relacionados

3.1 Marco de Referencia

Ingeniería de Menú

La ingeniería de menú es una metodología de gestión financiera y operativa que clasifica los ítems de un menú según su margen de contribución y su popularidad, con el propósito de orientar decisiones de precio, posicionamiento y promoción. Fue desarrollada por Kasavana y Smith [17], quienes propusieron una matriz de dos por dos que combina popularidad alta o baja, determinada por si el porcentaje de ventas del ítem supera el 70% de la popularidad promedio del menú, y margen de contribución alto o bajo, determinado por comparación con el margen ponderado de todos los ítems. LeBruto, Quain y Ashley [4] extendieron posteriormente este modelo incorporando el costo laboral como una tercera dimensión de análisis.

Predicción de Demanda

La predicción de demanda es el proceso de estimar la cantidad de productos o servicios que serán requeridos en un periodo futuro, a partir del análisis de datos históricos y variables contextuales [3]. En el sector de restaurantes, una estimación precisa de la demanda es determinante para la gestión eficiente del inventario, la reducción del desperdicio alimentario y la estabilidad financiera del negocio. Una subestimación genera desabastecimiento y pérdida de ventas; una sobreestimación produce excedentes, deterioro de insumos y aumento de costos operativos.

Margen de Contribución

El margen de contribución es la diferencia entre el precio de venta de un plato y sus costos variables directos. Representa el valor monetario que cada ítem aporta a cubrir los costos fijos del negocio y generar utilidad [17]. Para clasificar un plato, el margen individual se compara

con el margen de contribución ponderado del menú, que resulta de dividir la suma de los márgenes totales de todos los platos vendidos entre el número total de unidades vendidas en el periodo analizado.

Sistema de Soporte a la Toma de Decisiones

Un sistema de soporte a la decisión basado en computador es una aplicación diseñada para asistir a los responsables de la toma de decisiones mediante el procesamiento y organización de información relevante. Estos sistemas facilitan el acceso oportuno a los datos necesarios para evaluar alternativas, generan recordatorios o alertas en momentos críticos del proceso, apoyan la formulación de acciones apropiadas y permiten identificar patrones emergentes en la información disponible [18].

Inteligencia Artificial y Machine Learning

La inteligencia artificial se ocupa del desarrollo de sistemas capaces de realizar tareas asociadas a la inteligencia humana, mediante algoritmos capaces de analizar grandes volúmenes de datos y generar inferencias, predicciones o recomendaciones de manera automatizada [19]. El aprendizaje automático (machine learning) es una rama de la IA que desarrolla algoritmos capaces de aprender patrones a partir de datos y generar predicciones sin ser programados explícitamente para cada tarea [20]. El ML se clasifica en tres paradigmas según la naturaleza de los datos de entrada: aprendizaje supervisado, no supervisado y por refuerzo [20].

Series de Tiempo

Una serie de tiempo es una secuencia de observaciones medidas en intervalos regulares de tiempo [21]. Su comportamiento se descompone en cuatro partes: tendencia, que describe la dirección de largo plazo de los datos (ascendente, descendente, estable); estacionalidad, que expresa variaciones periódicas de frecuencia fija asociadas al calendario, como el día de la semana o el mes del año; ciclo, que representa fluctuaciones de periodo variable generalmente ligadas a factores económicos; y ruido, que agrupa las variaciones aleatorias que ningún componente sistemático explica [21].

Variables Involucradas

Las ventas históricas por plato constituyen la variable principal del sistema. Corresponden al conjunto de registros transaccionales generados por el punto de venta del restaurante, donde cada observación incluye el identificador del plato, la cantidad de unidades vendidas, la fecha, la hora y el día de la semana. Esta secuencia de registros conforma la serie de tiempo sobre la cual se entrenan los modelos de predicción de demanda [1]. Schmidt et al. [1] identificaron la media de ventas semanal como la variable con mayor capacidad predictiva en modelos aplicados a restaurantes reales.

Los costos e indicadores de rentabilidad son el conjunto de variables financieras que permiten evaluar el desempeño económico de cada plato del menú: el costo estimado de producción, el precio de venta y el margen de contribución. El margen de contribución es el indicador más relevante para la gestión financiera del menú, ya que expresa en términos absolutos cuánto aporta cada plato a la rentabilidad del negocio [5].

3.2 Trabajos Relacionados y Diferenciadores del Proyecto

3.2.1 Trabajos Relacionados

La literatura sobre predicción de ventas y rentabilidad en el sector restaurantero se organiza en dos líneas principales: modelos de ML para estimación de demanda, y metodologías de análisis financiero del menú.

Schmidt et al. [1] compararon modelos de ML aplicados a datos reales de ventas diarias de un restaurante mediano. Las herramientas utilizadas incluyeron LSTM, Temporal Fusion Transformer (TFT), regresiones lineales y enfoques ensemble, incorporando como variables el día de la semana, días festivos y el historial de ventas de los 14 días previos. Los modelos lineales resultaron superiores para predicción a un día (sMAPE de 19.6%), mientras que los modelos recurrentes (LSTM y TFT) fueron más precisos en horizontes semanales. A pesar de estos aportes, el estudio no modela la demanda por plato individual, no incorpora variables financieras y carece de una interfaz operativa para el administrador.

Kim [2] y Groene y Zakharov [10] comparten el interés por incorporar variables contextuales externas para mejorar la predicción de demanda. Kim [2] desarrolló un modelo de redes neuronales profundas para predecir la demanda de 384 ítems de menú, combinando datos de ventas del periodo 2021–2023 con variables meteorológicas como temperatura y precipitación,

logrando un coeficiente de correlación de Pearson promedio de $r = 0,7945$. Groene y Zakharov [10], en cambio, optaron por XGBoost con variables de clima y datos externos semiestructurados, evaluado en un restaurante de comida rápida en Alemania perteneciente a una franquicia internacional; demuestran que el modelo supera a los métodos de estimación manual incluso en entornos con recursos tecnológicos limitados. Ambos estudios omiten el análisis de rentabilidad por plato y no proponen herramientas de visualización para la toma de decisiones administrativas.

Chae, Sheu y Park [11] compararon modelos de ML y deep learning aplicados a datos de ventas por plato de una de las cadenas de restaurantes más grandes de Estados Unidos, incorporando datos macroeconómicos y de la pandemia por COVID-19 para mejorar la precisión. El estudio está orientado a cadenas con amplia infraestructura tecnológica y no es directamente transferible a restaurantes pequeños o medianos sin adaptaciones sustanciales.

Bujalance-López et al. [12] analizaron 108 artículos publicados entre 1997 y 2023 sobre gestión de ingresos en restaurantes, identificando la combinación de predicción de demanda con análisis de rentabilidad como la frontera de investigación más activa del campo. La revisión confirma que la transformación digital post-COVID ha acelerado la adopción de herramientas analíticas en el sector, aunque la mayoría de los sistemas documentados requieren infraestructura tecnológica avanzada.

3.2.2 Diferenciadores del Proyecto

A diferencia de los trabajos anteriores, el presente proyecto se enfoca en la integración de dos líneas que operan de forma independiente en la literatura revisada. Schmidt et al. [1], Kim [2], Groene y Zakharov [10] y Chae et al. [11] se centran en la predicción de demanda sin incorporar análisis de ingeniería de menú.

Las metodologías predominantes en predicción de demanda son LSTM, TFT y XGBoost, mientras que la ingeniería de menú sigue siendo el marco de referencia para el análisis financiero. Las limitaciones reportadas de forma recurrente son la dependencia de infraestructura tecnológica avanzada, la ausencia de herramientas de visualización para usuarios no técnicos y la falta de integración entre predicción e ingeniería de menú en un mismo sistema. El aspecto que los estudios revisados no han resuelto es el desarrollo de una plataforma unificada que articule predicción de demanda, clasificación por platos y soporte a la toma de decisiones en un entorno accesible para la administración de restaurantes PyME, brecha que el sistema propuesto busca cubrir directamente.

Caracterización del Conjunto de Datos

Contents

2.1 Descripción del problema	2
2.1.1 Formulación del problema	3
2.1.2 Sistematización del problema	3
2.2 Objetivos del Proyecto	4
2.2.1 Objetivo General	4
2.2.2 Objetivos Específicos	4
2.3 Justificación	5
2.4 Alcance y Limitaciones	6
2.4.1 Alcance	6
2.4.2 Limitaciones	6
2.4.3 Exclusiones	7
2.4.4 Entregables	7
2.5 Metodología	7
2.5.1 Tipo de Estudio	7
2.5.2 Fases del proyecto	8

Este capítulo responde a la primera parte del objetivo específico 1. Todas las cifras se obtienen con el script `codigo/eda_restaurante.py`, que permite reproducirlas sobre el archivo original.

4.1 Descripción general del conjunto de datos

El conjunto *Small Restaurant Multi-Channel Data 2023–2025* [16] corresponde a un restaurante independiente del Reino Unido. El archivo `Anonymized_Restaurant_Sales_Data.csv` contiene 4.385 registros a nivel de línea de pedido y catorce campos, sin valores faltantes (Cuadro 4.1).

Cuadro 4.1: Diccionario de datos del archivo transaccional

Campo	Descripción
OrderID	Identificador de pedido anonimizado
Date	Fecha del pedido (día/mes/año)
DayOfWeek	Día de la semana
Time	Hora del pedido
Category	Categoría del plato
Line item name	Nombre del plato
Quantity	Unidades vendidas en la línea
Price Per Item	Precio unitario (£)
Gross Sales	Ventas brutas ($\text{Quantity} \times \text{Price Per Item}$)
Est. Cost	Costo estimado de producción
Est. Profit	Margen estimado ($\text{Gross Sales} - \text{Est. Cost}$)
OrderType	Delivery o Collection
Payment	Método de pago
Cancelled	Indicador de cancelación

Se excluyen los 24 pedidos cancelados (0,55%), lo que deja 4.361 registros válidos, 62 platos distintos y un periodo entre el 3 de enero de 2023 y el 31 de diciembre de 2025. Se verificó que la columna `DayOfWeek` coincide con el día calendario de la fecha en el 100 % de los registros.

4.2 Análisis exploratorio

4.2.1 Estacionalidad

Semanal. No existe ningún registro en domingo durante los tres años, por lo que el restaurante opera de lunes a sábado. El sábado concentra 2.035 unidades, casi el doble que el viernes (1.167), segundo día de mayor demanda (Figura 4.1). Este patrón coincide con el día de la semana como variable de alta capacidad predictiva reportada por Schmidt et al. [1].




Figura 4.1: Unidades vendidas por día de la semana, 2023–2025. No hay operación los domingos.

Mensual. La participación promedio de cada mes dentro de su año desciende de 11,2 % en enero a 5,6 % en diciembre. Este descenso no puede atribuirse a estacionalidad pura, porque coincide con la tendencia decreciente descrita en la sección 4.2.2: con solo tres años, ambos efectos no se pueden separar con confianza.

4.2.2 Tendencia

La demanda cae de forma sostenida: 3.671 unidades en 2023, 2.215 en 2024 y 1.232 en 2025, cerca de -40% por año (Cuadro 4.2 y Figura 4.2). La serie no presenta meses sin registros, por lo que la caída refleja el comportamiento del negocio y no un problema de calidad de datos.

Cuadro 4.2: Demanda y ventas por año

Año	Unidades	Ventas brutas (£)	Pedidos
2023	3.671	19.015,75	727
2024	2.215	11.689,00	429
2025	1.232	7.775,50	242




Figura 4.2: Demanda mensual total, enero de 2023 a diciembre de 2025.

4.2.3 Distribución por categoría y por plato

Cuadro 4.3: Platos, unidades y ventas por categoría

Categoría	Platos	Unidades	Ventas (£)
EXTRAS	18	3.504	12.777,50
SOUPS	7	1.155	9.832,00
MAIN COURSES	8	1.044	8.338,50
APETISERS	13	1.026	4.825,75
DRINKS	7	255	571,00
SPECIAL ORDERS	3	73	713,50
Restaurant DEALS	6	47	1.296,50
Friday Specials	1	14	125,50

EXTRAS concentra el mayor volumen con un valor unitario bajo; SOUPS y MAIN COURSES generan más ventas por unidad (Cuadro 4.3). Los precios por plato van de £1 a £40, con mediana de £7,42. La demanda está concentrada: los diez platos más vendidos suman el 55,3 % de las unidades, mientras que 25 platos venden menos de 50 unidades en tres años y 5 venden menos de 10.

Intermitencia de la demanda. De los 938 días hábiles del periodo, solo 661 registran al menos una venta. A nivel de plato la serie diaria es mayoritariamente cero: el plato mediano no se vende en el 94,8 % de los días hábiles, e incluso el plato más frecuente tiene 71,6 % de días sin venta. Agregando por semana, el plato mediano sigue sin ventas en el 73,5 % de las semanas. Este hallazgo condiciona el diseño del módulo predictivo (sección 4.4).

4.3 Estructura de costos y margen

La razón `Est. Cost/Gross Sales` tiene media 0,3498 y desviación estándar 0,0007: el costo estimado es un 35 % fijo del precio, valor que coincide con el extremo superior del rango reportado por la National Restaurant Association [13]. En consecuencia, la correlación entre precio medio y margen unitario por plato es prácticamente 1. En este dataset, el eje de margen de la matriz de ingeniería de menú ordena los platos por precio y no por eficiencia de costos. Esta limitación, anticipada en la sección 2.4.2, debe declararse al interpretar la clasificación.

Como verificación de viabilidad, la matriz de Kasavana y Smith [17] sobre el periodo completo, con margen ponderado de £3,51 y umbral de popularidad de 1,13 % de las unidades, clasifica 11 platos como estrella, 13 como caballo de arado, 24 como puzzle y 14 como perro.

4.4 Variables de demanda y rentabilidad

Del análisis se derivan tres implicaciones para el diseño que deben validarse con el director:

1. El calendario de predicción excluye los domingos en lugar de tratarlos como demanda cero.
2. La partición entrenamiento/prueba debe ser temporal (los meses más recientes como prueba), para evaluar el modelo en el régimen de demanda vigente.
3. Dada la intermitencia, predecir cada plato por día produce series casi nulas. Se propone un único modelo global sobre todos los platos (con categoría y precio como variables), priorizar el horizonte semanal y reportar métricas sobre los platos con volumen suficiente. Además, SMAPE se indefiniría cuando valor real y predicho son ambos cero, por lo que esos casos deben tratarse de forma explícita en el capítulo 7.

Cuadro 4.4: Variables identificadas para los módulos del sistema

Variable	Módulo	Justificación
Unidades vendidas por plato y periodo	Predicción (objetivo)	Variable a predecir; base de la popularidad.
Día de la semana	Predicción	Estacionalidad semanal marcada (sección 4.2.1).
Rezagos y medias móviles de ventas	Predicción	Historial reciente como predictor principal [1].
Índice temporal	Predicción	Captura la tendencia decreciente (sección 4.2.2).
Mes	Predicción	Posible estacionalidad anual, confundida con tendencia.
Categoría y precio del plato	Predicción	Permiten compartir información entre platos con pocas ventas.
Precio, costo y margen unitario	Rentabilidad	Eje de margen de la matriz de ingeniería de menú.

Diseño del Sistema

Contents

3.1	Marco de Referencia	10
3.2	Trabajos Relacionados y Diferenciadores del Proyecto	12
3.2.1	Trabajos Relacionados	12
3.2.2	Diferenciadores del Proyecto	13

Este capítulo responde a la segunda parte del objetivo específico 1 (requisitos del DSS) y al objetivo específico 2 (flujos de información entre módulos). Los requisitos se derivan del alcance (sección 2.4.1), de las funciones de un sistema de soporte a la decisión [18] y de los hallazgos del capítulo 4.

5.1 Especificación de requisitos

5.1.1 Requisitos funcionales

5.1.2 Requisitos no funcionales

5.1.3 Restricciones del sistema

5.2 Arquitectura del sistema

5.2.1 Visión general de la arquitectura

El sistema se organiza en cuatro módulos con responsabilidades separadas y un almacén de resultados que los desacopla. El entrenamiento de modelos se ejecuta fuera de línea; el dashboard solo lee resultados ya calculados, lo que cumple RNF-03 y RNF-05. Se propone Python como lenguaje único (pandas, scikit-learn, XGBoost y TensorFlow/Keras) y Streamlit para el dashboard, por permitir construir una interfaz web sin separar frontend

y backend. Esta elección de tecnologías es una propuesta pendiente de validación con el director.

5.2.2 Módulo de ingesta de datos

Lee el CSV, valida el esquema (RF-01), depura los datos y construye dos tablas: la serie de ventas por plato y periodo sobre el calendario lunes–sábado, y el catálogo de platos con categoría, precio y margen unitario (RF-02).

5.2.3 Módulo de predicción de demanda

Construye las variables del Cuadro 4.4, entrena y compara XGBoost y LSTM con partición temporal (RF-03), selecciona el modelo de mejor desempeño y genera las proyecciones diarias y semanales por plato (RF-04).

5.2.4 Módulo de ingeniería de menú

Calcula el margen de contribución ponderado y el umbral de popularidad, y clasifica cada plato dos veces: con unidades históricas (RF-05) y con unidades proyectadas (RF-06). La comparación entre ambas clasificaciones produce las alertas (RF-07).

5.2.5 Interfaz de visualización

Dashboard web con tres vistas: proyección de demanda por plato (RF-08), matriz de ingeniería de menú con alertas (RF-07, RF-09) y desempeño del modelo (RF-11), con filtros comunes (RF-10) y exportación (RF-12).

5.3 Flujos de información entre módulos

La Figura 5.1 y el Cuadro 5.4 describen los datos que intercambian los módulos.

5.4 Decisiones pendientes de validación

1. Tecnologías propuestas: Python y Streamlit (sección 5.2.1).




Figura 5.1: Flujo de información entre los módulos del sistema.

2. Enfoque de modelo global para todos los platos y prioridad del horizonte semanal, por la intermitencia de la demanda (sección 4.4).
3. Tratamiento de SMAPE cuando valor real y predicho son cero.
4. Periodo de referencia de la clasificación histórica (año completo o últimas semanas), dada la tendencia decreciente.

Cuadro 5.1: Requisitos funcionales (formato tipo IEEE)

ID	Descripción	Prior.	Criterio de aceptación	Trazabilidad
RF-01	Cargar el archivo transaccional y validar su esquema.	Alta	Rechaza archivos sin las 14 columnas esperadas e informa cuáles faltan.	Ingesta; sec. 4.1
RF-02	Depurar los datos: excluir cancelados, convertir fechas y construir la serie por plato sin domingos.	Alta	La serie resultante no contiene cancelados ni domingos.	Ingesta; sec. 4.2.1
RF-03	Entrenar y evaluar los modelos XGBoost y LSTM con partición temporal.	Alta	Reporta MAE, RMSE y SMAPE de cada modelo sobre el periodo de prueba.	Predicción; obj. 3, 4
RF-04	Generar la proyección de demanda por plato en horizonte diario y semanal.	Alta	Existe una predicción no negativa por plato y periodo del horizonte.	Predicción; sec. 2.4.1
RF-05	Clasificar los platos en la matriz de ingeniería de menú con datos históricos de un periodo seleccionado.	Alta	Cada plato queda en una de las cuatro categorías según margen ponderado y umbral del 70 %.	Rentabilidad; [17]
RF-06	Clasificar los platos con la demanda proyectada.	Alta	Clasificación calculada con unidades predichas y márgenes vigentes.	Rentabilidad
RF-07	Generar alertas cuando la categoría proyectada de un plato difiere de la histórica.	Media	Se lista cada plato con cambio de categoría, su categoría actual y la proyectada.	Rentabilidad; Visualización
RF-08	Mostrar la demanda histórica y proyectada por plato.	Alta	Gráfica con histórico y proyección del plato seleccionado.	Visualización
RF-09	Mostrar la matriz de ingeniería de menú con indicadores de rentabilidad.	Alta	Gráfico de cuadrantes con margen y popularidad de cada plato.	Visualización
RF-10	Filtrar por categoría de menú, plato y periodo.	Media	Todas las vistas se actualizan según el filtro aplicado.	Visualización
RF-11	Mostrar las métricas de error del modelo vigente.	Media	El dashboard presenta MAE, RMSE y SMAPE.	Visualización; obj. 4

Cuadro 5.2: Requisitos no funcionales (formato tipo IEEE)

ID	Atributo	Prior.	Especificación	Verificación
RNF-01	Usabilidad	Alta	Un usuario sin formación en ciencia de datos consulta la proyección de un plato y su categoría sin asistencia.	Prueba guiada con lista de tareas.
RNF-02	Comprensibilidad	Alta	Etiquetas y alertas en lenguaje operativo, sin términos estadísticos sin explicar.	Revisión de textos de la interfaz.
RNF-03	Rendimiento	Media	Las vistas del dashboard cargan en menos de 3 s con resultados precalculados.	Medición en el equipo de desarrollo.
RNF-04	Reproducibilidad	Alta	Semillas fijas y versiones de librerías registradas; mismo resultado en ejecuciones repetidas.	Doble ejecución y comparación.
RNF-05	Mantenibilidad	Media	Módulos separados; cambiar el modelo predictivo no exige modificar el dashboard.	Revisión de dependencias entre módulos.
RNF-06	Portabilidad	Media	Ejecución en un portátil sin GPU dedicada.	Ejecución en los equipos del proyecto.
RNF-07	Transparencia	Alta	El sistema informa que el margen proviene de un costo estimado fijo del 35 %.	Presencia del aviso en la vista de la matriz.

Cuadro 5.3: Restricciones del sistema

ID	Tipo	Restricción
RST-01	Datos	El sistema se entrena y valida sobre un único restaurante [16].
RST-02	Alcance	Sin variables externas, integración con punto de venta ni gestión de inventarios (sección 2.4.3).
RST-03	Tecnológica	Herramientas de código abierto, sin costo de licencias.
RST-04	Operativa	Prototipo en entorno local; no se despliega en producción.

Cuadro 5.4: Flujos de información entre módulos

Origen	Destino	Información	Frecuencia
CSV	Ingesta	Registros transaccionales sin procesar	Al cargar datos
Ingesta	Predicción	Serie de unidades por plato y periodo (lunes-sábado)	Al cargar datos
Ingesta	Ing. de menú	Catálogo: plato, categoría, precio, margen unitario, unidades históricas	Al cargar datos
Predicción	Ing. de menú	Unidades proyectadas por plato y horizonte	Tras cada entrenamiento
Predicción	Almacén	Proyecciones y métricas MAE, RMSE y SMAPE	Tras cada entrenamiento
Ing. de menú	Almacén	Clasificación histórica, proyectada y alertas	Tras cada proyección
Almacén	Dashboard	Resultados filtrados según la consulta	Por consulta del usuario

Desarrollo del Prototipo

Contents

4.1	Descripción general del conjunto de datos	14
4.2	Análisis exploratorio	15
4.2.1	Estacionalidad	15
4.2.2	Tendencia	16
4.2.3	Distribución por categoría y por plato	17
4.3	Estructura de costos y margen	18
4.4	Variables de demanda y rentabilidad	18

6.1 Preprocesamiento de los datos

6.2 Módulo de predicción de demanda

6.2.1 Modelo XGBoost

6.2.2 Modelo LSTM

6.2.3 Selección del modelo

6.3 Módulo de ingeniería de menú

6.3.1 Cálculo del margen de contribución ponderado

6.3.2 Clasificación dinámica del menú

6.4 Dashboard web

6.4.1 Tecnologías empleadas

6.4.2 Funcionalidades implementadas

6.5 Integración del sistema

Validación del Sistema y Resultados

Contents

5.1	Especificación de requisitos	20
5.1.1	Requisitos funcionales	20
5.1.2	Requisitos no funcionales	20
5.1.3	Restricciones del sistema	20
5.2	Arquitectura del sistema	20
5.2.1	Visión general de la arquitectura	20
5.2.2	Módulo de ingesta de datos	21
5.2.3	Módulo de predicción de demanda	21
5.2.4	Módulo de ingeniería de menú	21
5.2.5	Interfaz de visualización	21
5.3	Flujos de información entre módulos	21
5.4	Decisiones pendientes de validación	21

7.1 Métricas de evaluación

7.2 Resultados de los modelos de predicción

7.2.1 Resultados de XGBoost

7.2.2 Resultados de LSTM

7.2.3 Comparación de desempeño

7.3 Validación funcional del prototipo

7.4 Análisis de resultados

CAPÍTULO 8

Conclusiones

CAPÍTULO 9

Trabajo Futuro

Anexo: Declaración sobre el uso de Inteligencia Artificial

En concordancia con las políticas de integridad académica de la Pontificia Universidad Javeriana Cali, se declara el uso de herramientas de Inteligencia Artificial generativa durante la elaboración de este trabajo.

Durante la elaboración del anteproyecto se utilizó Claude de Anthropic como herramienta de apoyo para mejorar la redacción, solicitando excluir palabras vacías que no añaden valor semántico relevante al contenido central, sobreadjetivación y palabras tortuosas.

Todo el contenido generado fue revisado críticamente, verificado y editado por los autores, quienes asumen la responsabilidad final sobre la integridad académica, el contenido, los resultados y las conclusiones de este documento.

Bibliografía

- [1] A. Schmidt, M. W. U. Kabir, and M. T. Hoque, “Machine learning based restaurant sales forecasting,” *Machine Learning and Knowledge Extraction*, vol. 4, no. 1, pp. 105–130, 2022.
- [2] S. Kim, “Development of an AI-based restaurant menu demand prediction model utilizing sales and meteorological data,” *Food Science and Biotechnology*, vol. 34, no. 15, pp. 3597–3606, 2025.
- [3] M. Rodrigues, V. Miguéis, S. Freitas, and T. Machado, “Machine learning models for short-term demand forecasting in food catering services: A solution to reduce food waste,” *Journal of Cleaner Production*, vol. 435, p. 140265, 2024.
- [4] S. M. LeBruto, W. J. Quain, and A. A. Ashley, “Menu engineering: A model including labor,” *FIU Hospitality Review*, vol. 13, no. 1, pp. 41–49, 1995.
- [5] B. M. Noone and G. Cachia, “Menu engineering re-engineered: Accounting for menu item substitutes in pricing and menu placement decisions,” *International Journal of Hospitality Management*, vol. 87, p. 102504, 2020.
- [6] D. S. Muñoz Pinzón, K. T. Valencia-Rivero, Y. P. Caviativa-Castro, and J. S. Castillo-Bustos, “Estado actual de la adopción de la industria 4.0 en pymes colombianas: desafíos y oportunidades,” *Revista Politécnica*, vol. 20, no. 39, pp. 99–118, 2024.
- [7] Asociación Nacional de Empresarios de Colombia (ANDI), “El sector de alojamiento y servicios de comida en colombia,” tech. rep., Asociación Nacional de Empresarios de Colombia (ANDI), 2023.
- [8] Departamento Administrativo Nacional de Estadística (DANE), “índice de precios al consumidor – diciembre de 2023,” tech. rep., Departamento Administrativo Nacional de Estadística (DANE), 2024.
- [9] Asociación Colombiana de la Industria Gastronómica (ACODRES), “Caída en ventas del sector gastronómico en 2023,” tech. rep., Asociación Colombiana de la Industria Gastronómica (ACODRES), 2023.

-
- [10] N. Groene and S. Zakharov, “Introduction of AI-based sales forecasting: how to drive digital transformation in food and beverage outlets,” *Discover Artificial Intelligence*, vol. 4, no. 1, 2024.
- [11] B. K. Chae, C. Sheu, and E. O. Park, “The value of data, machine learning, and deep learning in restaurant demand forecasting: Insights and lessons learned from a large restaurant chain,” *Decision Support Systems*, vol. 184, p. 114291, 2024.
- [12] L. Bujalance-López, L. González-Serrano, M. P. Lechuga Sancho, and P. Talon-Ballester, “Restaurant revenue management: a systematic literature review and future challenges,” *British Food Journal*, vol. 127, no. 6, pp. 2169–2196, 2025.
- [13] National Restaurant Association, “Working to reduce food waste,” tech. rep., National Restaurant Association, 2023.
- [14] World Resources Institute and WRAP, “The business case for reducing food loss and waste: Restaurants,” tech. rep., World Resources Institute and WRAP, 2019.
- [15] D. Roy, E. Spiliotopoulou, and J. de Vries, “How data-driven decisions help restaurants stay competitive.” *Harvard Business Review*, October 2023.
- [16] Tee, “Small restaurant multi-channel data (2023–2025).” <https://www.kaggle.com/datasets/omotayokupx/uk-small-restaurant-multi-channel-data>, 2025.
- [17] M. L. Kasavana and D. I. Smith, *Menu Engineering: A Practical Guide to Menu Analysis*. Lansing, MI: Hospitality Publications, 1982.
- [18] T. H. Payne, “Computer decision support systems,” *Chest*, vol. 118, no. 2, pp. 47S–52S, 2000.
- [19] J. M. Helm, A. M. Swiergosz, H. S. Haeberle, *et al.*, “Machine learning and artificial intelligence: Definitions, applications, and future directions,” *Current Reviews in Musculoskeletal Medicine*, vol. 13, pp. 69–76, 2020.
- [20] A. F. A. H. Alnuaimi and T. H. K. Albaldawi, “Machine learning classification techniques: A review,” *BIO Web of Conferences*, vol. 97, p. 00133, 2024.
- [21] R. J. Hyndman and G. Athanasopoulos, *Forecasting: Principles and Practice*. Melbourne, Australia: OTexts, 3 ed., 2021.

